

Катедри за рачунарство и информатику
Математичког факултета
Универзитета у Београду

Одлуком Катедре за рачунарство и информатику и Наставно-научног већа Математичког факултета (на 430. Седници ННВ одржаној 27.02.2026) именовани смо за чланове Комисије за преглед и одбрану мастер рада

Развој скалабилних апликација заснованих на вештачкој интелигенцији употребом технологије Кубернетес

кандидата **Александра Јаковљевића**, студента мастер академских студија Математичког факултета Универзитета у Београду, број индекса 1131/2024. После прегледа рукописа који је доставио кандидат **Александар Јаковљевић**, подносимо Катедри за рачунарство и информатику следећи

Извештај

У раду се реализује систематско емпиријско поређење ХАСП и КЕДА механизма хоризонталног аутошкалирања у контексту контејнеризованог сервиса за инференцију модела вештачке интелигенције. Поређење је засновано на асинхроној архитектури са RabbitMQ редом порука као распоређивачем порука, где се сервис за инференцију скалира или на основу искоришћености процесорске јединице (ХАСП) или на основу дубине реда порука (КЕДА).

Експериментална поставка је направљена тако да оба механизма скалирају исти циљни ресурс, са идентичним параметрима захтева и ограничења, истим опсегом реплика и истим апликативним кодом, док се мења искључиво сигнал на основу кога се доноси одлука о скалирању. У складу с тим, тежиште рада није на изградњи општег водича за развој скалабилних апликација, већ на контролисаном емпиријском поређењу два механизма скалирања. Изградња скалабилног сервиса служи као реалистична подлога на којој се то поређење спроводи, а главни допринос су квантитативни налази о понашању два сигнала скалирања под истим условима.

Пројектована експериментална поставка је омогућила контролисано поређење два механизма скалирања над истом апликативном логиком и инфраструктуром. Затим је уведен композитни индекс ефикасности аутошкалирања (АЕИ) као синтетички показатељ који спаја кумулативни заостатак, прекорачење нивоа услуге и просечан број реплика у јединствену метрику за упоредну анализу. Сprovedена је и детаљна емпиријска анализа понашања оба механизма, укључујући анализу осетљивости ХАСП прага, осетљивости КЕДА прага на дужину реда и формулисани су закључци засновани на конкретним квантитативним показатељима.

Рад чини шест поглавља (Увод, Преглед литературе, Методологија, Имплементација, Резултати и анализа и Закључак). Списак коришћене литературе садржи 34 ставке и дат је на крају рада. Прво поглавље је уводног типа. У другом поглављу представљени су теоријски и технолошки концепти на којима почива експериментална поставка: контејнеризација, оркестрација, механизми аутоматског скалирања у Кубернетесу, асинхрона обрада и редови порука, инференција модела вештачке интелигенције као радно оптерећење, као и преглед постојећих истраживања и идентификоване празнине у литератури. Треће поглавље описује методологију: избор технологија, системску архитектуру, Кубернетес ресурсе и манифесте, стратегије скалирања, планове оптерећења, метрике евалуације и експериментални протокол. У четвртом поглављу описана је имплементација система. Пето поглавље садржи резултате и анализу, као и детаљно поређење ХАСП и КЕДА механизма у оба профила оптерећења, анализу осетљивости параметара и синтетички преглед налаза. Закључно, шесто поглавље сумира основне закључке рада и идентификује правце будућег истраживања. Рад садржи укупно 120 страна. Развијени систем је доступан као софвер отвореног кода, на адреси <https://github.com/AlexJakovljevic/master-rad> и организован је као моно-репозиторијум, чиме је омогућено заједничко верзионисање свих компоненти система

Рад садржи квалитетан приказ релевантних појмова, техника и радова из домена софтверског инжењерства, контејнеризације, скалирања и асинхроне обраде, опис импелентираних система који омогућују планирана експериментална поређења, опис извршених екперимената, приказ и анализу добијених експерименталних резултата, као и извођење адекватних закључака и давање препорука за дизајн.

Закључак

Увидом у текст рада дошли смо до закључка да је рад квалитетно написан, да је кандидат јасно приказао изложену проблематику од основних појмова, до њихове креативне и технолошке примене. Рад **Развој скалабилних апликација заснованих на вештачкој интелигенцији употребом технологије Кубернетес** кандидата **Александра Јаковљевића** у потпуности задовољава захтеве који се постављају у изради мастер рада и са задовољством предлагемо да се одобри његова јавна одбрана.

др Владимир Филиповић, ред. проф.

др Младен Николић, ванр. проф.

др Александар Картељ, ванр. проф.